

DETEKCIJA SPAM PORUKA (SMS SPAM DETECTION) – DOKUMENTACIJA PROJEKTA

Studenti: Helena Zvocak

Ivona Pranjić

IKT – KV2

1. UVOD I OPIS PROBLEMA

SMS spam detekcija je važan zadatak u području obrade prirodnog jezika (eng. *Natural Language Processing – NLP*), koji ima značajnu primjenu u svakodnevnom životu, posebice u problemu filtriranja neželjene pošte putem tekstualnih poruka. S porastom broja korisnika mobilnih uređaja, spam poruke postale su ozbiljan problem jer mogu sadržavati neželjene, zlonamjerne ili reklamne sadržaje. Učinkovit sustav za prepoznavanje i filtriranje spama može značajno poboljšati korisničko iskustvo, povećati sigurnost i smanjiti količinu nevažnih ili potencijalno štetnih poruka. Za implementaciju sustava za detekciju SMS spama korišten je javno dostupan skup podataka s platforme Kaggle, koji sadrži poruke označene kao „ham” (ne-spam) i „spam” (neželjene). Dataset se nalazi u CSV formatu, gdje svaki redak predstavlja jednu SMS poruku, a kolone sadrže tekst poruke i pripadajuću klasifikaciju. Glavni cilj ovog projekta je razviti sustav koji će automatski prepoznavati spam poruke na temelju njihova sadržaja, koristeći različite tehnike obrade prirodnog jezika i algoritme strojnog učenja. Osim toga, cilj je postići visok stupanj točnosti i preciznosti u klasifikaciji poruka kako bi se minimizirali lažno pozitivni i lažno negativni rezultati. U realizaciji projektnog zadatka korištene su metode umjetne inteligencije, konkretno strojno učenje i umjetne neuronske mreže. Za klasifikaciju poruka razvijeni su dva modela – Naive Bayes klasifikator kao klasični algoritam strojnog učenja, te jednostavna umjetna neuronska mreža implementirana pomoću biblioteka TensorFlow i Keras. Ovi modeli trenirani su na označenim podacima, pri čemu su automatski učili obrasce karakteristične za spam i ham poruke. Time je omogućena potpuno automatizirana klasifikacija tekstualnih poruka, čime projekt direktno demonstrira praktičnu primjenu umjetne inteligencije u kontekstu svakodnevne digitalne komunikacije.

2. ODABIR ARHITEKTURE MREŽE

Poglavlje 2. prikazuje cjelokupni proces izgradnje sustava za prepoznavanje neželjenih (spam) poruka korištenjem modela strojnog učenja. Eksperiment se temelji na javno dostupnom skupu podataka koji sadrži SMS poruke označene kao *spam* ili *ham* (ne-spam poruke).


2.1. Učitavanje i priprema podataka

U ovom koraku obavljena je detaljna priprema skupa podataka kako bi se omogućila učinkovita primjena algoritama strojnog učenja. Skup podataka koji se koristi sastoji se od SMS poruka koje su označene kao legitimne („ham”) ili neželjene („spam”), a učitane iz CSV datoteke uz posebno definirano kodiranje kako bi se osigurala ispravna interpretacija znakova. Budući da su izvorni nazivi stupaca bili generički i neinformativni, preimenovani su u smislenije nazive, pri čemu stupac s oznakama poruka nosi naziv „label”, a stupac s tekstualnim sadržajem poruka naziv „Text”. Budući da algoritmi strojnog učenja zahtijevaju rad s numeričkim podacima, tekstualne oznake „ham” i „spam” transformirane su u numeričke vrijednosti 0 i 1. Nadalje, kako bi se omogućila kvalitativna analiza podataka, uklonjene su sve prazne vrijednosti u

tekstualnom stupcu, a sve poruke konvertirane su u nizove znakova. Na temelju tako pripremljenih podataka izračunata je prosječna duljina poruke u broju riječi, što je korisna informacija za definiranje parametara u modelima temeljenima na sekvencama. Također je identificiran ukupan broj jedinstvenih riječi koje se pojavljuju u tijelu, što se kasnije koristi za određivanje veličine vokabulara prilikom vektorizacije teksta. U završnoj fazi pripreme podataka provedena je podjela skupa na trening, validacijski i testni dio, pri čemu se 60% podataka koristi za treniranje modela, 20% za validaciju tijekom treniranja, a preostalih 20% za konačnu evaluaciju modela. Ovakva podjela omogućuje pouzdano praćenje performansi modela i sprječava overfittinga.

2.2. Istraživačka analiza podataka

Istraživačka analiza podataka provedena je s ciljem boljeg razumijevanja strukture i raspodjele samog skupa podataka prije pristupanja izgradnji modela. Analizirana je raspodjela klasa, odnosno broj poruka koje su označene kao "ham" (legitimne) i "spam" (neželjene). Vizualizacijom putem stupčastog dijagrama (Slika 1) uočeno je da skup podataka nije savršeno izbalansiran – broj legitimnih poruka značajno premašuje broj neželjenih, što može predstavljati izazov pri treniranju modela i potencijalno utjecati na njegovu sposobnost detekcije spama.



Slika 1 Raspodjela klasa

Nadalje, izračunata je prosječna duljina poruka u broju riječi, što omogućuje uvid u tipične tekstualne obrasce i pomaže u optimizaciji vektorizacijskih i sekvencijskih parametara kod modela neuronske mreže. Također je analiziran vokabular skupa podataka, pri čemu je izračunat ukupan broj jedinstvenih riječi koje se pojavljuju u svim porukama. Ova informacija je ključna za definiranje maksimalnog broja tokena u vektorizaciji, što direktno utječe na ulaznu dimenziju modela. Provedene analize osigurale su jasniji pregled nad sadržajem skupa podataka i omogućile donošenje informiranih odluka pri izgradnji i konfiguraciji klasifikacijskih modela.

2.3. Priprema podataka za modeliranje

Skup podataka podijeljen je na tri dijela: skup za treniranje, validacijski skup i testni skup, u omjeru 60:20:20. Ova podjela provedena je kako bi se omogućilo pouzdano treniranje modela, njegovo podešavanje tijekom treniranja te konačna i nepristrana evaluacija performansi na podacima koje model prethodno nije vidio. Prvo je izvorni skup slučajnim odabirom razdijeljen na 80 % podataka za treniranje i validaciju te 20 % za testiranje. Zatim je taj skup za treniranje dodatno podijeljen tako da 75 % podataka bude iskorišteno za treniranje, a preostalih 25 % za validaciju, čime se ukupno dolazi do omjera 60 % za treniranje, 20 % za validaciju i 20 % za testiranje. Na ovaj način osigurava se da model uči na jednom dijelu podataka, podešava se na drugom, a objektivno testira na trećem, čime se minimizira rizik od prenaučivosti i omogućuje realistična procjena generalizacijskih sposobnosti modela. Za usporedbu našeg izgrađenog modela za klasifikaciju SMS spam poruka koristili smo Naive Bayes model jer se radi o jednostavnom, ali iznimno učinkovitom klasifikatoru za zadatke obrade prirodnog jezika. Naive Bayes temelji se na Bayesovom teoremu uz pretpostavku uvjetne neovisnosti značajki, što ga čini posebno brzim i pogodnim za rad s velikim tekstualnim skupovima podataka. Osim što se lako implementira i ne zahtijeva veliku količinu resursa, često postiže konkurentne rezultate u odnosu na složenije modele, osobito kod problema poput detekcije neželjene pošte gdje razlike u riječima između spam i ham poruka mogu biti izražene. Korištenjem Naive Bayes modela omogućili smo jednostavnu, ali pouzdanu referentnu točku za evaluaciju našeg naprednijeg modela. Nakon treniranja modela, izvršena je evaluacija na testnom skupu. Prikazani su osnovni metrički pokazatelji točnosti, preciznosti, odziva i F1-mjere, kao i matrica zabune radi vizualne analize performansi

2.4. Izgradnja neuronske mreže za klasifikaciju

Sljedeći korak bio je razvoj jednostavne neuronske mreže (NN) kako bi se provjerilo može li se dobiti bolji rezultat korištenjem dubljeg modela. Za ovu svrhu korišten je TensorFlow i Keras API. Prvo je primijenjena TextVectorization tehnika kako bi se tekstualni podaci pretvorili u cjelobrojne sekvence. Ukupan broj tokena ograničen je na broj jedinstvenih riječi u skupu, dok je duljina izlazne sekvence određena na temelju prosječne duljine poruka. Model je građen na sljedeći način:

- **Embedding sloj:** Za pretvorbu riječi u semantičke vektore dimenzije 128.
- **GlobalAveragePooling1D i Flatten sloj:** Za smanjenje dimenzionalnosti.
- **Potpuno povezani (dense) sloj:** S 32 neurona i ReLU aktivacijom.
- **Batch Normalization:** Za stabilizaciju učenja.
- **Dropout sloj:** Radi sprečavanja prenaučivosti.
- **Izlazni sloj:** S jednim neuronom i sigmoid aktivacijskom funkcijom za binarnu klasifikaciju.

Model je treniran uz pomoć *EarlyStopping* mehanizma i *TensorBoard* za praćenje performansi. Korišten je Adam optimizator i binarna unakrsna entropija kao loss funkcija.

3. PROCES TRENIRANJA MREŽE

Proces treniranja neuronske mreže započinje pripremom tekstualnih podataka u obliku koji mreža može interpretirati. Nakon podjele skupa podataka, tekstualne poruke su prošle kroz proces vektorizacije pomoću TextVectorization sloja koji pretvara tekst u nizove cijelih brojeva. Ovaj sloj normalizira tekst, uklanja


interpunkciju te generira jednake duljine nizova temeljem unaprijed definirane duljine sekvence. Zatim su ti nizovi proslijeđeni u embedding sloj, koji svakoj riječi dodjeljuje vektor realnih vrijednosti i tako omogućuje mreži da uči o semantičkim odnosima među riječima. Nakon embedding sloja, arhitektura mreže uključuje GlobalAveragePooling1D sloj, flatten sloj, skriveni potpuno povezani sloj s 32 neurona i aktivacijskom funkcijom ReLU, te sloj za normalizaciju aktivacija (BatchNormalization) kako bi se poboljšala stabilnost i brzina učenja. Uveden je i Dropout sloj s postotkom izbacivanja od 30 % kako bi se smanjio rizik od prenaučivosti. Na izlazu se koristi Dense sloj s jednim neuronom i sigmoid funkcijom aktivacije, koja vraća vrijednosti između 0 i 1, što je idealno za binarnu klasifikaciju (spam ili ne-spam). Mreža je trenirana pomoću Adam optimizatora, a kao funkcija gubitka korišten je binarni unakrsni entropijski gubitak (eng. *binary crossentropy loss*). Tijekom treniranja korišten je rani prekid (eng. *Early stop*) kako bi se zaustavilo treniranje ukoliko se validacijski gubitak ne poboljšava kroz nekoliko epoha, čime se dodatno smanjuje rizik od overfittinga. Uz to, korišten je i TensorBoard za vizualizaciju metrika tijekom treniranja. Mreža je trenirana kroz različit broj epoha, a uspješnost modela kontinuirano je praćena na validacijskom skupu. Završni model evaluiran je na testnom skupu kako bi se dobila objektivna procjena njegove učinkovitosti u klasifikaciji nepoznatih poruka. Što se tiče optimizacije hiperparametara, kroz treninge smo mijenjali broj epoha. Prvi trening započeli smo s 10 epoha, što je dalo dosta dobre rezultate od čak 98% preciznosti. Međutim, kasnije smo dodali još 5 epoha, odnosno promijenili broj epoha u 15 radi postizanja optimalnih rezultata svih klasifikacijskih metrika.

3.1 Vizualizacija tijekom treniranja

Kako bi se bolje razumjelo ponašanje modela tijekom procesa treniranja, provedena je vizualizacija metrika točnosti i gubitka kroz epohe. Grafički prikaz prikazuje kako se točnost na skupu za učenje i validaciju razvijala kroz vrijeme, te omogućuje detekciju potencijalnih problema poput underfittinga i overfittinga. Paralelno su praćeni i gubici modela, što je dodatno pomoglo u optimizaciji arhitekture i hiperparametara. Ovi grafovi predstavljaju važan alat za interpretaciju performansi modela te osiguravaju transparentnost cijelog procesa učenja.


4. EVALUACIJA MREŽE

Nakon procesa treniranja neuronske mreže, provedena je detaljna evaluacija performansi modela korištenjem standardnih metrika kao što su točnost (eng. *Accuracy*), gubitak (eng. *Loss*), preciznost (eng. *Precision*), odziv (eng. *Recall*), F1 mjera, kao i analiza matrice zabune (eng. *Confusion matrix*). Na grafu točnosti i gubitka kroz epohe (Slika 2) može se primijetiti jasan trend poboljšanja performansi modela tijekom treniranja, ali bez tendencije modela ka overfittingu.




Slika 2 Grafički prikaz (a) preciznosti i (b) gubitka

Točnost na skupu za treniranje kontinuirano je rasla te se stabilizirala vrlo blizu 100%, dok je točnost na validacijskom skupu također pokazivala uzlazni trend, pri čemu se zaustavila na vrijednosti oko 98%. Istovremeno, vrijednosti gubitka na oba skupa pokazivale su pad, što ukazuje na uspješnu optimizaciju. Kako bismo detaljnije razumjeli ponašanje modela, korištena je matrica zabune, kojom se analizirao broj točno i netočno klasificiranih uzoraka. Model jednostavne neuronske mreže (Slika 3) pokazao je izuzetno visoku preciznost, klasificirajući sve „ham“ poruke ispravno, s malim udjelom netočno klasificiranih „spam“ uzoraka.




Slika 3 Matrica zabune jednostavni NN model

Radi usporedbe, izvedba modela temeljenog na Naive Bayes klasifikatoru bila je nešto slabija, sa zamjetno većim brojem pogrešno klasificiranih “spam” uzoraka.(Slika 4)



Slika 4 Matrica zabune Naive Bayes model

Shodno navedenome, evaluacija neuronskog modela ukazuje na to da trenirani model generalizira dobro neviđene podatke te pokazuje visoku razinu točnosti i pouzdanosti u klasifikaciji. Ukupan rezultat svih metrika radi lakše usporedbe prikazan je u obliku stupčastog grafa na Slika 5.



Slika 5 Ukupni rezultat metrika klasifikacije


Sa slike uočavamo kako je ostvaren optimalan rezultat točnosti klasifikacije od čak 98%, preciznost, koja predstavlja mjeru čija “cijena” nam je u ovom problemu dosta “skupa”, ostvarena je rezultatom 100%. Odziv se pokazao na maksimalno 83%, te balansirana mjera F1 od 91%. Osim grafičkih prikaza dobivenih standardnim vizualizacijskim alatima, u naš projekt smo ugradili i TensorBoard (Slika 6), alat koji omogućuje detaljan uvid u tijek treniranja modela. Korištenjem TensorBoarda mogli smo vizualizirati strukturu neuronske mreže, nadzirati proces učenja te analizirati distribuciju težina i druge relevantne aspekte modela. To nam je omogućilo dublje razumijevanje ponašanja modela tijekom treniranja i lakše prepoznavanje potencijalnih problema poput overfittinga ili neuravnoteženih klasa, čime smo dodatno unaprijedili proces evaluacije i optimizacije modela.





Slika 6 Primjer jednog od grafičkih prikaza u TensorBoard


Ranije smo naveli konačne, po nama optimalne rezultate projekta. Na sljedećim slikama prikazan je proces evaluacije i optimizacije parametara u 3 eksperimenta:



1. eksperiment: 10 epoha








2. eksperiment: 14 epoha





3. eksperiment: 30 epoha (early stop na 18)





5. ZAKLJUČAK

Projekt detekcije SMS spam poruka uspješno je demonstrirao kako se primjenom tehnika obrade prirodnog jezika i strojnog učenja može učinkovito razlikovati legitimna (ham) komunikacija od neželjene (spam) pošte. Korištenjem javno dostupnog skupa podataka te pažljivom pripremom i analizom podataka, postavljeni su čvrsti temelji za izgradnju klasifikacijskih modela. Usporedbom jednostavnog Naive Bayes klasifikatora i vlastite neuronske mreže, pokazano je da duboki modeli, uz pravilnu konfiguraciju i regularizaciju, postižu značajno bolje rezultate u klasifikacijskim metrikama. Završni model temeljen na jednostavnoj neuronskoj mreži ostvario je visoku točnost (98%), savršenu preciznost (100%) i solidnu vrijednost odziva (83%), što ukazuje na iznimnu sposobnost pravilne klasifikacije spam poruka uz minimizaciju lažno pozitivnih rezultata. Vizualizacije putem TensorBoarda dodatno su pridonijele boljem razumijevanju procesa treniranja i omogućile pravovremenu optimizaciju arhitekture modela i hiperparametara.